


Büyük Dil Modellerinde (LLM) Halüsinasyon Filtreleme


Kesinlik Spektrumu: Çoklu Ajan Çerçevesi ve Sıcaklık (Temperature) Optimizasyonu



4 Kişilik Geliştirici Ekibi
Hafta 1 Proje Sunumu ve Yol Haritası

Yapay Zeka Her Zaman Doğruyu Söylemez

Büyük Dil Modelleri (LLM) gerçeği bilmediklerinde duraksamazlar; son derece ikna edici kurgular üretirler. Kritik karar alma süreçlerinde bu durum, yapay zekaya olan güveni temelden sarsar.



Problemi görmezden gelmek veya ondan kaçınmak yerine, onu izole edip filtreleyen algoritmik bir sistem inşa etmeliyiz.


Amacımız: 4 Kademeli Bir Doğrulama Hunisi İnşa Etmek

Çekirdek Konsept:

Hedefimiz, halüsinasyonları önlemeye çalışmak yerine onları bir "stres testi" olarak kullanmaktır.



'Sıcaklık' (Temperature) Parametresi Nedir?



Sıcaklık = Yüksek

Yüksek Sıcaklık modeli yaratıcı, rastgele ve risk almaya açık hale getirir. Halüsinasyon riski maksimumdur.




Sıcaklık = Düşük

Düşük Sıcaklık modeli odaklı, tutarlı, deterministik ve katı hale getirir. Sadece en olası ve net cevabı üretir.

Biz, bu parametreyi ajanlarımızın kişiliklerini ve katılıklarını belirlemek için ana kontrol kolu olarak kullanacağız.

Paradoks: Neden Kasıtlı Olarak Halüsinasyon Üretiyoruz?



Kontekst


Sistemimizin kalbi, **1. Ajan**'ın her zaman halüsinasyon görmesini sağlamaktır. Sıcaklığı maksimuma çekerek, sistemimize kasten en kötü senaryoyu (yanlış ama ikna edici bilgi) enjekte ediyoruz.

- Güçlü bir filtre, test edilmeden kanıtlanamaz.
- 1. Ajan ham veri ve alternatif (hatalı) senaryoları üretir.
- Diğer ajanlar bu 'virüslü' veriyi ayıklayarak kendi doğrulama kapasitelerini kanıtlarlar.

4-Ajanlı Çerçeve Mimarisi

	Ajan 1	Ajan 2	Ajan 3	Ajan 4
Sıcaklık (Temperature)	En Yüksek	Orta-Yüksek	Orta-Düşük	En Düşük
Rol & Sistem Görevi	Ham Veri ve Kurgu Üretici	İlk Filtre ve Bağlam Analizi	Mantıksal Doğrulama ve Hata Ayıklama	Nihai Karar Mercii
Karakteristik Çıktı	Kasıtlı Halüsinasyon	Esnek Yorum	Katı Analiz	En Net ve Kesin Cevap

Proje Altyapısı: Nasıl Yapmayı Planlıyoruz?




Python (Merkez Mantık): 4 farklı API'nin asenkron yönetimi, ajanlar arası veri akışı ve sıcaklık parametrelerinin algoritmik kontrolü.

Çoklu API Entegrasyonu: Farklı LLM modellerinin tek bir çatı altında konuşlandırılması.


Streamlit (Kullanıcı Arayüzü): Kullanıcıların prompt girebildiği, 4 ajanın karar sürecini canlı izleyebildiği ve filtrelenmiş net cevabı görebildiği interaktif web uygulaması.

3 Haftalık Ölçeklendirme Yol Haritası




Hafta 1: Parametre Optimizasyonu

Tek Model, Farklı Sıcaklıklar.
(Şu Anki Aşama)



Hafta 2: Model Çeşitliliği


Aynı Aile, 4 Farklı Model Varyasyonu.



Hafta 3: Çapraz Doğrulama Ağı


4 Farklı Marka LLM Entegrasyonu.

Faz 1 ve 2: Kontrollü Ortamda Filtreleme



1. Hafta - Mevcut Durum

Aynı modelin üzerine 4 farklı sıcaklık değeri uygulayarak mimarinin temel veri akışını ve Streamlit arayüzünü ayağa kaldırmak.



2. Hafta - Model Çeşitliliği

Parametreler sabitlendikten sonra, aynı LLM ailesinin 4 farklı spesifik modelini kullanarak sistemin farklı mimarilerdeki halüsinasyonları yakalama tepkisini ölçmek.

Faz 3: Nihai Sentez ve apraz Marka Doęrulaması

Projenin son haftasında,
halüsinasyon filtreleme sistemimiz
tek bir ekosistemden çıkarak global
bir yapay zeka jürisine dönüşecek.



Nihai Hedef: 4 farklı rakip markanın modellerini birbiriyle apraz kontrol ettirerek, tek bir modelin kör noktalarından kaynaklanan sistemik halüsinasyonları %100'e yakın bir oranda filtrelemek.

Hedeflenen Arayüz: Karmaşıklığı Basitleştirmek

○ ○ ○

Top block

[Kullanıcı Promptu]

Ajan Süreçleri

▼

▼

▼

▼

Doğrulanmış Çıktı

Güven Skoru: %99

Biz sadece API parametreleriyle oynamıyoruz; 4 kişilik ekibimizle, güvensiz yapay zeka çıktılarını alıp, Streamlit üzerinden son kullanıcının tamamen güvenebileceği "Kesinlik Spektrumundan" geçirilmiş, rafine ve hatasız bir gerçeklik motoru inşa ediyoruz.